

# 基于 YOLO v3 的生猪个体识别方法<sup>\*</sup>

金耀, 何秀文, 万世主, 刘仁鑫

(江西农业大学工学院, 南昌市, 330045)

**摘要:**为实现高效的猪只个体识别,提出一种基于机器视觉的生猪个体识别方法。通过采集母猪和仔猪个体图像,对图像进行扩充和筛选,制作训练集和测试集。试验采用基于 YOLO v3 的识别模型,并与 Faster RCNN 和 SSD 模型识别结果进行比较,结果表明:对仔猪的识别平均精度均值达 89.65%,准确率达 95.99%,召回率达 84.09%。对母猪的识别平均精度均值达 95.16%,准确率达 96.00%,召回率达 96.00%。相较于 Faster RCNN,该模型的识别速率是其 7 倍以上,相较于 SSD,该模型的平均精度均值提高 9%,说明该模型在识别速率和识别精度上都达到了较高水平。该研究可为猪只个体智能识别、数据监测及养殖信息化等提供理论依据。

**关键词:**猪只识别;机器视觉;深度学习;YOLO v3;图像采集;养殖信息化

**中图分类号:**S24: TP391.4 **文献标识码:**A **文章编号:**2095-5553 (2021) 02-0178-06

金耀, 何秀文, 万世主, 刘仁鑫. 基于 YOLO v3 的生猪个体识别方法[J]. 中国农机化学报, 2021, 42(2): 178—183

Jin Yao, He Xiuwen, Wan Shizhu, Liu Renxin. Individual pig identification method based on YOLO v3 [J]. Journal of Chinese Agricultural Mechanization, 2021, 42(2): 178—183

## 0 引言

近 10 年来,随着强农惠农富农政策的实施<sup>[1]</sup>,畜牧业呈现出加快发展势头,生猪等生产方式发生积极转变,规模化、标准化、产业化和区域化步伐加快。随着硬件平台的发展,计算机视觉技术正迅速的应用到各行各业中<sup>[2-5]</sup>。在畜牧养殖行业也不例外,诸多方面也已经取得了一定的进展。开展生猪全产业链数据监测,可以为农业农村大数据发展与应用提供可复制、可推广的经验做法。所以寻找一种更加可靠、精确、方便的生猪监测手段和方法显得异常迫切。

计算机视觉技术应用于畜牧养殖行业引起了国内外学者的广泛关注, Lee 等<sup>[6]</sup>利用 Kinect 相机对猪只的攻击行为进行识别,并采用 SVM 的方法对所发生的侵略行为进行分类; Kashiha 等<sup>[7]</sup>在各猪体背部涂上不同的图案编号,通过对获得的猪体俯视图像进行目标提取,并识别图案所在的位置,通过相似度匹配的方法来确定猪只具体的身份。Huang 等<sup>[8]</sup>通过提取猪只的 Gabor 和 LBP 特征组合并通过 PCA 降维的方式来对俯视群养猪进行身份识别。周勇钧等<sup>[9]</sup>提出了多特征 Camshift 和 Kalman 滤波结合的猪只智能跟

踪,实现多猪只的跟踪。仇益页<sup>[10]</sup>使用基于弦轴变换的猪只特征区域的识别完成了俯视条件下对猪只特征区域的识别。张天昊等<sup>[11]</sup>利用基于纹理特征的滤波方法排除颜色灰度相似背景的干扰,实现了远程视频采集的养殖场图像识别计数。但以上方法存在识别精度不高,检测效率低无法实现实时检测等诸多缺点。

YOLO(you only look once)<sup>[12]</sup>是一种端到端的目标检测算法。它将检测任务表述成一个统一的、端到端的回归问题<sup>[13-14]</sup>,并且以只处理一次图片得到位置和分类而得名。和 Fast RCNN<sup>[15-16]</sup>相比, YOLO 的背景错误不到 Fast RCNN 的一半,同时 YOLO 可以学到物体的泛化特征。该研究考察了江西省泰和县和瑞昌市的两个大北农旗下的生猪养殖场,了解到在生猪养殖场每个猪栏的猪只变动,包括其转栏、出栏等盘点工作均由人工记录并统计。为在生猪养殖场环境下实现非接触、低成本生猪个体识别,本文提出一种基于 YOLO v3 的生猪个体识别方法。

## 1 图像采集与处理

### 1.1 图像采集

图像采集于江西省吉安市泰和县绿色巨农养殖

收稿日期:2020 年 8 月 7 日 修回日期:2020 年 10 月 14 日

<sup>\*</sup>基金项目:江西省畜牧设施技术开发工程研究中心专项基金(赣发改高技(2019)277 号)

第一作者:金耀,男,1995 年生,浙江湖州人,硕士研究生;研究方向为机器视觉。E-mail: 1151840806@qq.com

通讯作者:何秀文,男,1975 年生,江西南昌人,硕士,副教授;研究方向为计算机视觉。E-mail: ithxw@163.com

场,养殖场内约有5 000头母猪。对养殖场母猪和仔猪采取多角度多场景的拍摄,共计拍摄图片3 000多张,30 s以上视频一百多条。为降低重叠率拍摄时主要以俯视图为主。如图1所示为采集到的母猪和仔猪原图。




图1 图像采集

Fig. 1 Graphic gathering

## 1.2 建立数据集

为提高试验鲁棒性,从拍摄的图片中选取2 000张较为清晰且不同角度的图片,将拍摄的视频进行取帧保存,并采用旋转、平移、缩放、添加噪声、裁剪等方式对数据进行扩充,最终获得15 000张图片。在扩充的数据集中选取符合试验需求的8 000张图片作为本次模型训练和测试的数据集,其中70%作为训练集,30%作为测试集。如图2所示,使用YOLO v3自带的yolo-mark标注工具,分别对仔猪和母猪使用矩形框进行标注。




图2 图像标注

Fig. 2 Image annotation

## 2 YOLO 模型构建与试验

YOLO模型从诞生开始就通过划分单元格来做检测,二代模型开始用批量归一化(Batch Normalization, BN)、加速收敛和避免过拟合的方法,把批量归一层和激活函数层连接到卷积层,随后采用一个单独的CNN网络模型实现端对端的目标检测。整个模型将输入的图片的尺寸调整到416像素×416像素大小,通过卷积神经网络处理预测结果并得到检测目标。相比R-CNN算法,YOLO模型是一个统一的框架,其速度更快且训练过程也是端对端的。

YOLO的CNN网络将输入的图片分割成 $S \times S$ 网格,每个单元格负责检测中心点落在该格子内的目标,若目标中心落在左下角一个单元格内,则该单元格负责预测这个目标。每个单元格预测若干个边界框以及边界框的置信度。置信度可以定义为 $Pr(object) \times IoU$ ,它包含两个方面,一是该边界框含有目标的可能性大小,二是该边界框的准确度。当该边界框是背景时 $Pr(object) = 0$ ,而当该边界框包含目标时 $Pr(object) = 1$ 。边界框的准确度可以用预测框与实际框的交并比(IoU)来表示。

### 2.1 YOLO v3 模型结构分析

YOLO v3的整个网络结构示意图,如图3所示。

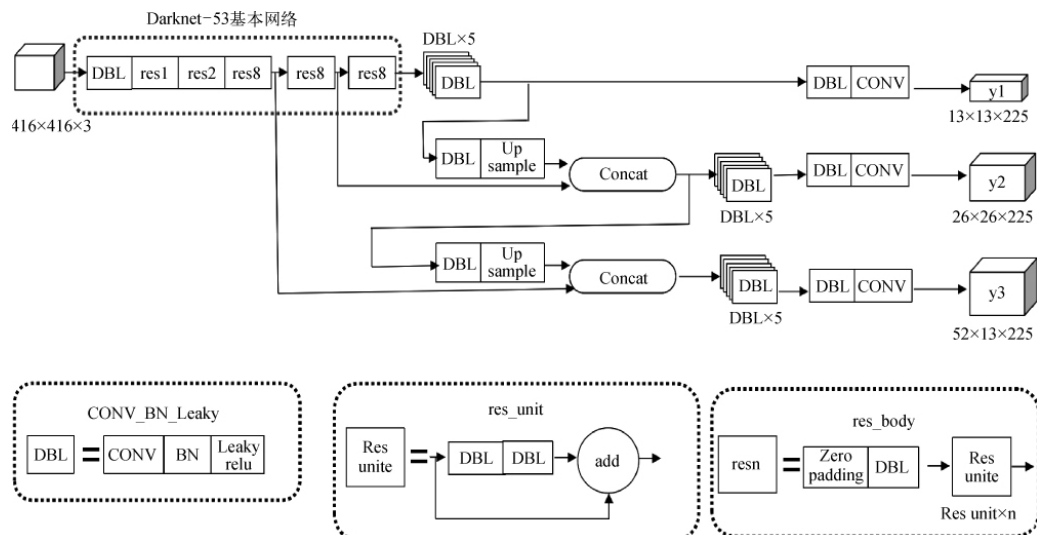


图3 YOLO v3 网络结构示意图

Fig. 3 Schematic diagram of YOLO v3 network structure

其中 DBL 层 (Darknetconv2d-BN-Leaky) 为 YOLO v3 的基本组件,由 CONV、BN 和 Leaky relu 组成。残差层是 YOLO v3 中的大组件,表示残差模块(res\_block)里面含有残差单元(Res unit)的个数,网络结构中的张量拼接层(concat)将 Darknet 网络的中间层和上采样层进行拼接,扩充了张量的维度。整个网络结构包含了 252 层,其中叠加层(add)有 23 层;BN 和 Leaky relu 有 72 层;CONV 有 75 层;上采样层和张量拼接层有 2 层,一共有 5 个残差模块,每个残差模块都会用一个零填充层(ZeroPadding)。

从图中可以看出 YOLO v3 输出了 3 个不同尺寸的特征图,y1,y2,y3,采用多尺度来对不同尺寸的目标进行检测。单元网络的精密程度决定了检测结果的精确程度,YOLO v3 的每个单元网络预测 3 个框,每个框有(x,y,w,h,c)五个参数分别表示预测框中心点的横纵坐标,预测框的长和宽及置信度。

基本的图像特征提取部分,YOLO v3 采用了 Darknet53 的网络结构。如图 4 所示,Darknet53 一共含有 53 层卷积,除去最后一个全连接层,共 52 个卷积层做主体网络。由 1 个 32 个过滤器的卷积核,经过 5 组重复的残差模块,残差模块中每个单元由 1 个单独的卷积层与一组重复执行的卷积层构成,重复执行的卷积层分别重复 1 次、2 次、8 次、8 次、4 次;在每个重复执行的卷积层中,先对输入图像执行 1×1 的卷积操作,再执行 3×3 的卷积操作,过滤器的数量先减半,再恢复,总共 52 层。

	Type	Filters	Size	Output
1	Convolutional 256	32	3 3	256
	Convolutional 128	64	3 3/2	128
	Convolutional Residual 128	32 64	1 1 3 3	128
	Convolutional	128	3 3/2	64 64
	Convolutional Residual 64	64 128	1 1 3 3	64
8	Convolutional	256	3 3/2	32 32
	Convolutional Residual	128 256	1 1 3 3	32 32
	Convolutional	512	3 3/2	16 16
8	Convolutional Residual	256 512	1 1 3 3	16 16
	Convolutional	1024	3 3/2	8 8
	Convolutional Residual	512 1024	1 1 3 3	8 8
Avgpool Connected Softmax			Global 1000	

图 4 Darknet53 网络结构示意图

Fig. 4 Schematic diagram of Darknet53 network structure

## 2.2 检测模型训练

本文采用 Darknet53 作为网络框架,模型在统一配置下进行训练,硬件平台 CPU 为 Inter i7 6700@3.4 GHz,GPU 为 GeForce GTX 1070,6 G 显存,16 G 运行内存,运行系统为 Windows10 专业版。CUDA 版本为 10.1,CUDNN 神经网络加速库版本为 10.1。

训练时设置动量因子(Momentum)为 0.9,该值影响梯度下降到最优值的速度。衰减系数(Decay)设置为 0.000 5,该值为权重正则项,为了让权重衰减到更小的值,防止模型过拟合。学习率(Learning\_rate)设置为 0.001。迭代次数与损失值变化如图 5 所示。




图 5 损失函数输出结果

Fig. 5 Output result of loss function

由图 5 可知,模型在迭代 2 000 次以前损失值迅速下降,在 2 000 次到 10 000 次的迭代中损失值缓慢减小,迭代 10 000 次以后模型损失值基本趋于稳定状态,此时损失值稳定在 0.27 左右,符合训练预期。本次模型训练总共进行了 12 000 次迭代训练,训练时每 1 000 次迭代保存一个训练模型,共得到 12 个训练模型。因模型在迭代 10 000 次以后损失值趋于平稳,故本试验只取前 10 000 次迭代的 10 个模型,进行模型评估。

为选取最优模型,本文采用多项指标对模型的性能进行评估,具体指标包括交并比(IoU)、准确率(P)、召回率(R)、调和平均值(F<sub>1</sub>)、平均精度均值(mAP)。

$$P = \frac{T_p}{T_p + F_p} \times 100\% \quad (1)$$

$$R = \frac{T_p}{T_p + F_N} \times 100\% \quad (2)$$

$$F_1 = \frac{2PR}{P + R} \quad (3)$$

$$mAP = \frac{1}{N} \sum_{K=1}^N PR \quad (4)$$

式中: T<sub>p</sub>——真正样本数量;

F<sub>p</sub>——假正样本数量;

N——检测样本类别数量;

F<sub>N</sub>——假负样本数量。

$IoU$  交并比为预测框和真实框交集部分面积与并集部分面积的比值,体现了预测的边界框与真实边界框的接近程度。

$$IoU_{pred}^{truth} = \frac{Area(\alpha \cap \beta)}{Area(\alpha \cup \beta)}$$

(5)

式中: $\alpha$ ——预测边界框;  
 $\beta$ ——目标物体真实边界框;  
 $Area$ ——面积, $cm^2$ 。

本试验只需识别生猪这一类目标物体故将  $N$  的值取为 1,交并比( $IoU$ )阈值的选择会直接影响准确率( $P$ )和召回率( $R$ )的大小。为了保证检测精度,选择  $IoU>50\%$  作为判断目标是否被正确检测。

表 1 列出了训练完成的 10 个模型相对应的指标参数。选择最优模型时不仅需要权衡准确率与召回率,同时也应该选择能够综合反映模型性能的指标。

表 1 输出模型参数比较

Tab. 1 Output model parameter comparison

模型	$mAP/\%$	$F_1/\%$	$P/\%$	$R/\%$	$IoU/\%$
1	83.89	84.54	86.88	82.32	60.81
2	90.58	91.11	91.98	90.26	68.27
3	90.07	91.73	92.37	91.09	69.55
4	88.00	90.22	91.97	88.54	68.63
5	91.22	92.09	91.71	92.47	69.36
6	90.21	91.74	92.19	91.30	70.03
7	89.72	91.16	91.57	90.75	68.85
8	88.97	90.56	90.03	91.09	67.62
9	89.39	91.02	93.58	88.60	70.16
10	90.05	91.28	92.61	89.99	70.55

$F_1$  是  $P$ 、 $R$  参数的加权调和平均指标, $mAP$  是综合衡量模型性能最为全面的指标,因此选择  $mAP$  和  $F_1$  数值最大的模型作为本次训练的最优模型。将表 1 中模型迭代 10 000 次得到的  $mAP$  值作为参数建立曲线图,变化曲线如图 6 所示,迭代次数在 5 000 次时,模型  $mAP$  达最大值 91.22%同时  $F_1$  也达到最大值 92.09%,故在本次训练出来的模型当中模型 5 为最优检测模型。




图 6  $mAP$  随迭代次数变化曲线图

Fig. 6  $mAP$  variation curve with the number of iterations

3 试验结果与讨论

3.1 母猪仔猪识别

以最优模型作为检测模型,分别对测试集中的母猪和仔猪进行识别,得到该模型的  $F_1$ 、 $P$ 、 $R$ 、 $IoU$  等各项指标参数。如表 2 所示为仔猪和母猪的识别参数对照表,从模型检测结果来看,母猪的  $mAP$  高达到 95.16%,而仔猪的  $mAP$  为 89.65%。因母猪体型较大数量较少,在图片检测过程中更容易识别。仔猪体型较小,数量较多,存在重叠、模糊等情况,相较于母猪识别难度更高,因此识别精度相对较低。如图 7 所示,图 7(a)和图 7(b)中的仔猪和母猪被正确识别,图 7(c)中存在被重复检测的仔猪,图 7(d)中存在被漏检的仔猪。

表 2 仔猪、母猪识别参数对比

Tab. 2 Comparison of identification parameters between piglets and sows

类别	$mAP/\%$	$F_1/\%$	$P/\%$	$R/\%$	$IoU/\%$
母猪	95.16	96.00	96.00	96.00	77.99
仔猪	89.65	89.65	95.99	84.09	73.22
平均	92.41	92.83	96.00	90.05	75.61




图 7 图像识别结果

Fig. 7 Image recognition result

3.2 不同算法模型比较

为验证本模型的可靠性,将本模型的试验结果与 Faster RCNN 和 SSD 算法模型进行对比,试验都在同一硬件配置下进行。表 3 列出了三种不同算法模型对生猪个体识别效果的参数对比,从表中可以看出 YOLO v3 模型的检测效率是 Faster RCNN 模型的 7 倍以上。对比 SSD 算法模型,YOLO v3 算法的  $mAP$



值与  $F_1$  值明显更高。综合上述, YOLO v3 网络模型兼具 Faster RCNN 的检测精度和 SSD 网络模型的检测效率, 是本试验的最优检测模型。

表 3 不同模型识别参数对比  
Tab. 3 Comparison of identification parameters of different models

方法	$mAP$ /%	$F_1$ /%	$IoU$ /%	主干网络	识别效率 $/(f \cdot s^{-1})$
YOLO v3	92.41	92.83	75.61	Darknet-53	23
Faster RCNN	90.48	89.67	80.22	VGG-16	3
SSD	80.13	78.15	76.56	VGG-16	25

## 4 结论

1) 该研究基于 YOLO v3 模型的目标检测框架。通过建立生猪识别的数据集对其进行训练和测试。模型对仔猪的识别, 准确率达 95.99%, 召回率达 84.09%。对母猪的识别, 准确率达 96.00%, 召回率达 96.00%。

2) 分别对数据集中的母猪和仔猪进行训练和识别, 提高了模型的各项参数指标, 母猪的  $mAP$  高达 95.16%, 而仔猪的  $mAP$  为 89.65%。得出母猪识别精度更高, 仔猪由于数量多、体型小、模糊重叠等因素, 识别效率相对较低。

3) 本试验模型相较于 Faster RCNN 识别效率提升 7 倍以上, 相较于 SSD 平均精度均值提高 9%, 说明该模型在识别速率和识别精度都达到了较高水平。

## 参 考 文 献

- [1] 贾少鹏, 高红菊, 杭潇. 基于深度学习的农作物病虫害图像识别技术研究进展[J]. 农业机械学报, 2019, 50(S1): 313-317.  
Jia Shaopeng, Gao Hongju, Hang Xiao. Research progress on image recognition technology of crop pests and diseases based on deep learning [J]. Transactions of the Chinese Society for Agricultural Machinery, 2019, 50 (S1): 313-317.
- [2] 许传悦, 田军, 王新铜, 等. 基于图像处理的大豆数量检测技术[J]. 科学技术创新, 2018(1): 77-78.
- [3] 张君军, 石志广, 李吉成. 人数统计与人群密度估计技术研究现状与趋势[J]. 计算机工程与科学, 2018, 40(2): 282-291.  
Zhang Junjun, Shi Zhiguang, Li Jicheng. Current researches and future perspectives of crowd counting and crowd density estimation technology [J]. Computer Engineering & Science, 2018, 40(2): 282-291.
- [4] 王玉亮, 刘贤喜, 苏庆堂, 等. 多对象特征提取和优化神经网络的玉米种子品种识别[J]. 农业工程学报, 2010, 26(6): 199-204, 389.  
Wang Yuliang, Liu Xianxi, Su Qingtang, et al. Maize

seeds varieties identification based on multi-object feature extraction and optimized neural network [J]. Transactions of the CSAE, 2010, 26(6): 199-204, 389.

- [5] 李继秀, 李啸天, 刘子仪. 基于 SSD 卷积神经网络的公交车下车人数统计[J]. 计算机系统应用, 2019, 28(3): 51-58.  
Li Jixiu, Li Xiaotian, Liu Ziyi. Statistics on number of people getting off bus based on SSD Convolutional Neural Network [J]. Computer Systems & Applications, 2019, 28 (3): 51-58.
- [6] Lee J, Jin J, Park D, et al. Automatic recognition of aggressive behavior in pigs using a kinect depth sensor [J]. Sensors, 2016, 16(5): 631.
- [7] Kashiha M, Bahr C, Haredasht S A, et al. The automatic monitoring of pigs water use by cameras [J]. Computers & Electronics in Agriculture, 2013, 90: 164-169.
- [8] Huang W J, Zhu W X, Ma C H, et al. Identification of group-housed pigs based on gabor and local binary pattern features [J]. Biosystems Engineering, 2018, 166: 90-100.
- [9] 周勇钧, 俞守华, 区晶莹. 多特征 Camshift 和 Kalman 滤波结合的猪只智能跟踪[J]. 广东农业科学, 2013, 40(9): 174-177, 188.  
Zhou Yongjun, Yu Shouhua, Qu Jingying. Pig intelligent tracking based on multi-feature Camshift algorithm combined with Kalman filter [J]. Guangdong Agricultural Sciences, 2013, 40(9): 174-177.
- [10] 仇益页. 基于弦轴变换的猪只特征区域的识别[D]. 镇江: 江苏大学, 2018.  
Qiu Yiye. A feature region identification method of pigs based on Chordal Axis Transform [D]. Zhenjiang: Jiangsu University, 2018.
- [11] 张天昊, 梁炎森, 何志毅. 图像识别计数在储备生猪统计的应用[J]. 计算机应用与软件, 2016, 33(12): 173-178.  
Zhang Tianhao, Liang Yansen, He Zhiyi. Applying image recognition and counting to reserved live pigs statistics [J]. Computer Applications and Software, 2016, 33 (12): 173-178.
- [12] 刘芳, 刘玉坤, 林森, 等. 基于改进型 YOLO 的复杂环境下番茄果实快速识别方法[J]. 农业机械学报, 2020, 51(6): 229-237.  
Liu Fang, Liu Yukun, Lin Sen, et al. Fast Recognition method for tomatoes under complex environments based on improved YOLO [J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51 (6): 229-237.
- [13] 何东健, 刘建敏, 熊虹婷, 等. 基于改进 YOLO v3 模型的挤奶奶牛个体识别方法[J]. 农业机械学报, 2020, 51(4): 250-260.  
He Dongjian, Liu Jianmin, Xiong Hongting, et al. Individual identification of dairy cows based on improved YOLO v3 [J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(4): 250-260.
- [14] 魏宏彬, 张端金, 杜广明, 等. 基于改进型 YOLO v3 的蔬

- 菜识别算法[J]. 郑州大学学报(工学版), 2020, 41(2): 7-12, 31.
- Wei Hongbin, Zhang Duanjin, Du Guangming, et al. Vegetable recognition algorithm based on improved YOLO v3 [J]. Journal of Zhengzhou University (Engineering Science), 2020, 41(2): 7-12, 31.
- [15] 刘小刚, 范诚, 李加念, 等. 基于卷积神经网络的草莓识别方法[J]. 农业机械学报, 2020, 51(2): 237-244.
- Liu Xiaogang, Fan Cheng, Li Jianian, et al. Identification method of strawberry based on Convolutional Neural Network [J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(2): 237-244.
- [16] 潘卫国, 刘博, 陈英昊, 等. 基于 YOLO v3 的交通标志牌检测识别[J]. 传感器与微系统, 2019, 38(11): 147-150.
- Pan Weiguo, Liu Bo, Chen Yinghao, et al. Traffic sign detection and recognition based on YOLO v3 [J]. Transducer and Microsystem Technologies, 2019, 38(11): 147-150.

## Individual pig identification method based on YOLO v3

Jin Yao, He Xiuwen, Wan Shizhu, Liu Renxin

(School of Engineering, Jiangxi Agricultural University, Nanchang, 330045, China)

**Abstract:** In order to realize efficient pig individual recognition, a pig recognition method based on machine vision was proposed. Training sets and test sets were made by collecting individual images of sows and piglets, and the images were expanded and screened. The identification model based on YOLO v3 was adopted and compared with the identification results of the Faster RCNN and SSD models. The results showed that the mean average precision of pig lets identification was 89.65%, the accuracy rate was 95.99%, and the recall rate was 84.09%. The mean average precision of sows identification was 95.16%, the accuracy rate was 96.00%, and the recall rate was 96.00%. The recognition rate of the model is 7 times higher than that of the Faster RCNN, and the average accuracy of the model is 9 percentage points higher than that of the SSD. The model reaches a high level in both the recognition rate and the recognition accuracy. This study can provide theoretical basis for intelligent identification, data monitoring and breeding informatization of pigs.

**Keywords:** pig identification; machine vision; deep learning; YOLO v3; image acquisition; aquaculture informatization

(上接第 170 页)

## Research on the segmentation method of adhesive chicken body based on concave point analysis

Zhang Baoquan<sup>1</sup>, Lu Huishan<sup>1</sup>, Wang Fujie<sup>1</sup>, Li Mingming<sup>1</sup>, Wang Xinyu<sup>2</sup>

(1. School of Mechanical Engineering, North University of China, Taiyuan, 030051, China;

2. School of Instrument and Electronics, North University of China, Taiyuan, 030051, China)

**Abstract:** In order to solve the problem of adhesion between chicken bodies, a new method of adhesion chicken body segmentation based on concave point analysis was proposed in this paper. In this method, the image was preprocessed by using the maximum interclass variance method combined with morphological operation under the different color space. By analyzing the outline of the convex defect in the adhesion region, the square template was used to determine the position of the concave point, and then the concave point was randomly matched to determine the correct matching mode of the concave point, and finally the segmentation of the adherent chicken body was realized. The results of segmentation experiments on different numbers of adhesion chickens show that this method could achieve the segmentation of multiple adhesion chickens, with an average segmentation accuracy rate of 92.8% and an average running time of 2.817 s, and compared with the extreme erosion combined concave point seek method and watershed segmentation method, the correct segmentation rates of the two methods were 63.4% and 71.6%, respectively. This method was superior to the other two methods. The experiment on segmentation of adhesion chickens in a real breeding environment shows that the paper method could achieve better segmentation of low-density adhesion chickens. The method in this paper could provide technical support for the subsequent monitoring of the individual health status of the flock.

**Keywords:** adhesion separation; concave point analysis; convex defect; OTSU